

LLMind2: un framework ontology-grounded e multi-agente per la valutazione scientifica del reasoning diagnostico con Large Language Models in salute mentale

Davide Ditolve Coautori da confermare
Affiliazione da confermare
email da confermare

22 giugno 2026

Sommario

L'impiego dei Large Language Models (LLM) nel dominio della salute mentale richiede metodologie di valutazione più severe rispetto a quelle comunemente adottate per applicazioni conversazionali generaliste. Il rischio non riguarda soltanto l'accuratezza del testo generato, ma la possibilità che un sistema produca inferenze nosologiche non tracciabili, confonda sistemi classificatori non equivalenti, o trasformi un supporto alla ricerca in una presunta decisione clinica. Questo articolo presenta LLMind2, un framework di ricerca progettato per studiare il reasoning diagnostico assistito da LLM attraverso tre principi: grounding esplicito su ICD-11 e ICD-11 Clinical Descriptions and Diagnostic Requirements (CDDR), benchmark controllato su casi DSM-5-TR, e decomposizione multi-agente orientata a separare triage, codifica nosologica, diagnosi differenziale, revisione dei casi, metodologia sperimentale e sicurezza.

La proposta estende il precedente lavoro LLMind Chat, che aveva mostrato la fattibilità di un approccio Retrieval-Augmented Generation (RAG) su ICD-11 per supportare professionisti della salute mentale [4]. La versione 2 sposta il focus da un singolo assistente RAG a un ambiente sperimentale più ampio, riproducibile con componenti locali e open source, in cui sorgenti statiche vengono normalizzate in un corpus interrogabile, i casi clinici sono gestiti come oggetti di benchmark versionati, gli agenti conversazionali sono dotati di ruoli espliciti e guardrail, e la valutazione combina metriche automatiche, rubriche esperte e analisi degli errori. L'articolo descrive il razionale scientifico, le domande di ricerca, il disegno metodologico, l'architettura concettuale e il protocollo di valutazione previsto. Eventuali integrazioni cloud sono trattate soltanto come opzioni di deployment e non come prerequisito scientifico. LLMind2 non è presentato come dispositivo diagnostico, ma come ambiente riproducibile per studiare quando, come e con quali limiti i LLM possano contribuire al reasoning nosologico in contesti di ricerca e formazione clinica.

Parole chiave: Large Language Models; Retrieval-Augmented Generation; ICD-11; DSM-5-TR; salute mentale; agenti conversazionali; benchmark clinico; human-in-the-loop evaluation; clinical decision support.

1 Introduzione

La classificazione dei disturbi mentali richiede l'integrazione di informazioni eterogenee: sintomi riportati, durata, compromissione funzionale, decorso, diagnosi differenziale, condizioni mediche o da sostanze, contesto culturale e livello di rischio. A differenza di altri domini medici in cui un segnale strumentale può avere un peso diagnostico determinante, in psicologia e psichiatria la diagnosi è spesso il risultato di un processo interpretativo distribuito, che combina colloquio

clinico, osservazione, anamnesi, criteri diagnostici e giudizio professionale. Manuali come DSM-5-TR e ICD-11 forniscono un linguaggio condiviso e criteri sistematici, ma la loro applicazione resta un compito complesso [1, 9, 10]. La complessità aumenta quando il ragionamento deve attraversare sistemi classificatori non sovrapponibili, per esempio quando casi formulati secondo DSM-5-TR vengono usati per valutare suggerimenti ancorati a ICD-11.

Questa caratteristica rende la salute mentale un caso di studio particolarmente rilevante per valutare i LLM. Un modello può generare una risposta linguisticamente plausibile anche quando non ha identificato correttamente il costrutto clinico sottostante; può inoltre omettere esclusioni fondamentali, sovrainterpretare dati insufficienti, o confondere somiglianza semantica con equivalenza diagnostica. Di conseguenza, una valutazione scientifica non può limitarsi a misurare se il nome di una diagnosi appare nell'output. Occorre valutare il percorso inferenziale: quali informazioni sono state usate, quali sono state ignorate, quali ipotesi alternative sono state considerate, quale incertezza è stata dichiarata e quali condizioni di non applicabilità sono state riconosciute.

I LLM hanno mostrato capacità notevoli nel generare testo, sintetizzare contenuti e rispondere a domande mediche [7, 8]. Tuttavia, nel dominio della salute mentale, il problema centrale non è soltanto produrre una risposta fluente. Un sistema utile alla ricerca deve rendere espliciti i propri ancoraggi, distinguere evidenze da ipotesi, mantenere traccia delle fonti, evitare diagnosi definitive su casi reali e consentire valutazioni riproducibili. La letteratura su RAG suggerisce che l'accesso a memoria non parametrica possa migliorare factuality, aggiornabilità e tracciabilità [5, 6], ma il semplice recupero di documenti non risolve da solo il problema clinico: occorre definire che cosa viene recuperato, come viene strutturato, quali agenti lo usano, quali output sono permessi e come l'intero processo viene valutato. In altri termini, il problema non è soltanto architetturale, ma epistemologico: un sistema di supporto al reasoning deve rendere auditabile il rapporto tra fonte nosologica, caso clinico, modello linguistico e giudizio umano.

Il lavoro precedente LLMind Chat ha proposto un sistema RAG basato su ICD-11 e Gemma 2 per supportare il processo diagnostico in psicologia e psichiatria, valutandolo su casi DSM-5-TR e con validazione esperta [4]. Quel lavoro ha mostrato che un modello generalista, quando ancorato a una knowledge base specialistica, può produrre suggerimenti più coerenti rispetto a modelli non adattati al compito. La versione 2 nasce da una domanda più ampia: come trasformare un assistente RAG in una piattaforma scientifica per sperimentare, comparare e governare sistemi LLM nel reasoning diagnostico?

LLMind2 è progettato come infrastruttura di ricerca. Non mira a sostituire il clinico, né a fornire diagnosi operative. Il suo scopo è costruire un ambiente controllato in cui studiare il contributo di LLM e agenti conversazionali in compiti come codifica ICD-11, diagnosi differenziale, revisione di casi benchmark, navigazione metodologica e controllo di sicurezza. In questa prospettiva, l'interfaccia applicativa non è il contributo principale: essa è un mezzo per rendere osservabili, versionabili e valutabili processi di reasoning che altrimenti resterebbero incorporati in conversazioni non strutturate. Il contributo scientifico è quindi duplice: da un lato una metodologia per costruire un corpus nosologico e un benchmark controllato; dall'altro un protocollo per valutare non soltanto l'esito finale, ma anche la qualità del processo inferenziale.

2 Dal sistema LLMind originale a LLMind2

Il paper originale ha introdotto LLMind Chat come applicazione RAG per ICD-11. La pipeline comprendeva l'estrazione del contenuto ICD-11 tramite API, l'integrazione con ICD-11-CDDR, la costruzione di prompt testuali per ciascun disturbo, l'indicizzazione vettoriale e l'interrogazione di un LLM locale. La valutazione era stata condotta usando i casi clinici DSM-5-TR e confrontando il comportamento del sistema con modelli di riferimento [4]. Il contributo principale era dimostrare che un modello open, arricchito da retrieval specialistico, poteva fornire supporto più pertinente nel dominio della salute mentale.

LLMind2 conserva questa intuizione ma modifica la domanda scientifica. Invece di chiedere soltanto se un singolo modello risponde correttamente a un caso, la piattaforma indaga quali componenti del processo contribuiscono alla qualità del reasoning. La distinzione è importante. Un errore può derivare da una retrieval query troppo ampia, da una sovrapposizione DSM/ICD non risolta, da leakage del gold standard nel prompt, da una risposta generativa troppo assertiva, da una rubrica di valutazione poco discriminante, o da una mancata separazione tra triage e diagnosi differenziale. La versione 2 introduce quindi una decomposizione funzionale del task.

La piattaforma organizza il processo in sei ruoli agentici: intake clinico, codifica ICD-11, supervisione della diagnosi differenziale, revisione dei casi benchmark, navigazione del protocollo di ricerca e guardrail di sicurezza. Tale organizzazione non implica che gli agenti producano verità clinica. Al contrario, serve a rendere più verificabile l'interazione tra fonti, vincoli e output. Ogni agente ha un perimetro dichiarato, input attesi, output ammessi, fonti consultabili e condizioni di handoff.

3 Domande di ricerca

La versione 2 è guidata da quattro domande di ricerca.

1. **RQ1 - Grounding nosologico.** In che misura un grounding esplicito su ICD-11/CDDR migliora coerenza, tracciabilità e appropriatezza dei suggerimenti rispetto a prompt senza retrieval o con retrieval non strutturato?
2. **RQ2 - Decomposizione multi-agente.** La separazione tra intake, codifica, diagnosi differenziale, revisione benchmark e sicurezza riduce errori di scope, leakage e overclaiming rispetto a un singolo assistente generalista?
3. **RQ3 - Valutazione cross-nosologica.** Quali limiti emergono quando casi DSM-5-TR vengono usati per valutare output ancorati a ICD-11, e come si possono modellare tali limiti nel protocollo sperimentale?
4. **RQ4 - Riproducibilità.** Un corpus statico normalizzato e versionato, interrogabile con strumenti locali e open source, può sostenere una pipeline agentica riproducibile senza sacrificare auditabilità scientifica?

Author action required. Confermare se queste quattro domande di ricerca riflettono l'obiettivo di dottorato. Se il paper deve essere inviato a una conferenza specifica, occorre adattare lunghezza, stile e priorità delle RQ al venue.

4 Background

4.1 LLM e salute mentale

La ricerca sugli LLM in ambito medico ha mostrato risultati promettenti su question answering, sintesi clinica e ragionamento testuale [7, 8]. Tuttavia, la salute mentale presenta caratteristiche peculiari. Le diagnosi sono spesso sindromiche, dipendono dal decorso temporale, richiedono esclusioni mediche e culturali, e sono sensibili alla qualità dell'informazione raccolta. Inoltre, la comorbidità e la sovrapposizione sintomatologica rendono insufficiente un approccio puramente classificatorio. Una vignetta clinica può contenere segnali compatibili con più ipotesi; alcune informazioni possono essere assenti; altre possono essere ambigue o dipendere dal modo in cui il caso è stato narrato. In questi contesti, un output utile non è necessariamente quello che produce subito una diagnosi, ma quello che organizza il problema, identifica incertezze, suggerisce differenziali plausibili e chiarisce quali dati sarebbero necessari per procedere.

In tale contesto, un LLM può essere utile come strumento di strutturazione, esplorazione e confronto, ma è rischioso se produce conclusioni assertive senza esplicitare incertezza, dati

mancanti e condizioni da escludere. La letteratura sui modelli clinici sottolinea infatti la necessita di mantenere supervisione umana, valutazione esterna e distinzione tra performance su benchmark e validita clinica reale [8]. Questo punto e cruciale per LLMind2: il sistema e progettato per misurare e rendere visibili le condizioni di affidabilita, non per mascherare l'incertezza dietro una conversazione naturale.

4.2 ICD-11, ICD-11-CDDR e DSM-5-TR

ICD-11 e la classificazione internazionale dell'Organizzazione Mondiale della Sanita, mentre DSM-5-TR e il manuale dell'American Psychiatric Association [1, 9]. Entrambi sono centrali nella pratica e nella ricerca, ma non sono intercambiabili. La ICD-11-CDDR fornisce descrizioni cliniche e requisiti diagnostici per disturbi mentali, comportamentali e del neurosviluppo [10]. Il DSM-5-TR Clinical Cases offre invece vignette utili per valutare il ragionamento su casi strutturati [2].

La scelta di usare casi DSM-5-TR per valutare un sistema ancorato a ICD-11 crea una tensione metodologica fertile ma delicata. Da un lato, i casi DSM consentono benchmark con gold standard. Dall'altro, il gold standard non coincide necessariamente con la formulazione ICD-11. LLMind2 tratta questa tensione come parte esplicita del disegno sperimentale, non come un dettaglio tecnico.

4.3 Retrieval-Augmented Generation e memoria esterna

RAG combina un modello generativo con una memoria esterna indicizzata, consentendo al sistema di recuperare contenuti rilevanti prima della generazione [5]. Nel dominio clinico, questo paradigma e particolarmente utile perche permette di separare parametri del modello e conoscenza specialistica, riducendo la dipendenza dalla memoria interna del LLM. Tuttavia, RAG non garantisce correttezza: retrieval irrilevante, chunking non ottimale, conflitto tra fonti e generazione non fedele restano problemi aperti [6].

4.4 Agenti conversazionali e decomposizione del reasoning

L'orchestrazione agentica viene qui interpretata in senso metodologico: non come moltiplicazione arbitraria di chatbot, ma come separazione controllata di responsabilita epistemiche. Un agente di intake non deve diagnosticare; un agente ICD-11 non deve trasformare automaticamente etichette DSM in codici ICD; un agente di benchmark non deve correggere il gold standard senza revisione umana; un guardrail non deve discutere dettagli clinici quando emergono rischio acuto o dati identificativi. La decomposizione consente di valutare failure modes specifici e di ridurre confusione tra compiti.

5 Materiali e fonti

5.1 Corpus ICD-11

Il corpus ICD-11 e ottenuto attraverso API e organizzato come tassonomia locale. Per LLMind2, l'attenzione primaria e sul Capitolo 6, relativo ai disturbi mentali, comportamentali e del neurosviluppo. A differenza di pipeline legacy basate su file statici intermedi, la versione 2 assume che l'estrazione primaria avvenga da API e che la base locale venga poi normalizzata in tabelle interrogabili. Ogni categoria deve conservare, quando disponibili, codice, titolo, descrizione, relazioni gerarchiche, inclusioni, esclusioni, termini indice e metadati utili alla ricerca. Questa rappresentazione consente di trattare ICD-11 non come un semplice documento testuale, ma come una struttura nosologica navigabile.

La scelta di estrarre ICD-11 tramite API ha una motivazione scientifica: riduce l'ambiguità introdotta da conversioni manuali, permette di ripetere l'estrazione, mantiene il legame con l'identificativo originale delle entità e consente di distinguere tra contenuto tassonomico e contenuto descrittivo. Nel contesto del benchmark, tale distinzione è importante per capire se il modello sta recuperando una categoria appropriata, se sta usando criteri diagnostici pertinenti, o se sta semplicemente generando una parafrasi plausibile.

5.2 ICD-11-CDDR

ICD-11-CDDR è usato come sorgente testuale per descrizioni cliniche, requisiti diagnostici, confini con normalità, esclusioni e differenziali. Nel disegno sperimentale, CDDR è considerato il riferimento nosologico principale per gli agenti ICD-11 e diagnosi differenziale. Il suo ruolo è diverso da quello della tassonomia ICD-11: mentre la tassonomia fornisce identificatori, gerarchie e categorie, CDDR offre il contenuto clinico che rende interpretabile la categoria. Per questa ragione, il corpus deve mantenere collegamenti tra categoria, descrizione diagnostica e sezioni testuali, evitando che il retrieval restituisca frammenti privi di contesto.

5.3 Casi DSM-5-TR

I casi DSM-5-TR Clinical Cases sono usati come materiale di benchmark e non come fonte di verità ICD-11. Ogni caso deve essere separato in campi distinti: presentazione o introduzione, discussione, diagnosi e metadati. La separazione è essenziale per evitare leakage: se il modello riceve la discussione o la diagnosi durante il test, il benchmark non misura più reasoning diagnostico ma recupero di informazione contaminata.

Il valore dei casi DSM-5-TR è duplice. Da un lato, essi offrono vignette cliniche sufficientemente strutturate per testare modelli in modo comparabile. Dall'altro, introducono una tensione metodologica perché il gold standard è formulato in un sistema diagnostico diverso da quello usato come grounding principale. Questa tensione non deve essere eliminata artificialmente: deve essere misurata. LLMind2 può quindi distinguere tra correttezza rispetto al gold standard DSM, plausibilità di mapping verso ICD-11 e qualità del ragionamento differenziale.

5.4 Corpus statico e riproducibile

La versione 2 introduce un corpus statico e versionato, interrogabile con strumenti locali e open source. La motivazione non è soltanto ingegneristica. Dal punto di vista scientifico, un corpus tabellare o documentale controllato consente di:

- congelare una specifica versione delle fonti;
- riprodurre le query o le ricerche effettuate dagli agenti;
- misurare quali sezioni sono state recuperate;
- separare retrieval strutturato e generazione;
- ridurre variazioni non controllate tra esecuzioni.

La rappresentazione unificata dei chunk agentici può contenere campi quali corpus, famiglia diagnostica, sezione, codice, testo, hash della fonte e versione dell'estrazione. Questa struttura abilita esperimenti in cui l'agente consulta soltanto l'intero Capitolo 6 oppure un sottoinsieme selezionato di sezioni, rendendo possibile uno studio sul trade-off tra ampiezza del contesto e precisione del retrieval. Implementazioni cloud, inclusa una possibile esportazione in BigQuery o l'uso di agenti gestiti, possono essere utili per scalare il prototipo o per dimostrazioni applicative, ma non costituiscono il nucleo scientifico del paper perché non sono necessariamente riproducibili gratuitamente o con strumenti aperti.




Figura 1: Pipeline riproducibile di costruzione del corpus in LLMind2. Le fonti ICD-11, ICD-11-CDDR e DSM-5-TR vengono trasformate in artefatti versionati e interrogabili localmente, separando tassonomia, contenuto descrittivo e casi benchmark.

5.5 Snapshot numerico degli artefatti

Per distinguere il contributo metodologico dai risultati sperimentali, questa sezione riporta uno snapshot statico degli artefatti presenti nella repository al momento della stesura. I valori non sono risultati clinici, ma numeriche di riproducibilit : descrivono la dimensione del corpus disponibile, dei casi di benchmark e degli artefatti agentici che il protocollo puo usare.

Artefatto	Numero
Categorie ICD-11 estratte	720
Casi DSM-5-TR strutturati	104
Chunk ICD-11 per datastore agentico	523
Chunk DSM-5-TR per datastore agentico	853
Chunk agentici totali	1 376
Playbook conversazionali	6
Subagent definiti	7
PDF sorgente disponibili per datastore	3

Tabella 1: Snapshot quantitativo degli artefatti riproducibili. Le numeriche indicano la scala del corpus e dell’orchestrazione, non la performance diagnostica del sistema.




Figura 2: Distribuzione quantitativa degli artefatti di corpus. Il grafico rende evidente la separazione tra tassonomia ICD-11, casi benchmark DSM-5-TR e chunk documentali usati dagli agenti.

6 Disegno del sistema di ricerca

6.1 Principi di progetto

LLMind2 segue cinque principi metodologici:

1. **Grounding prima della generazione.** Ogni output nosologico deve essere preceduto da retrieval o consultazione di fonti strutturate.
2. **Separazione dei compiti.** Gli agenti hanno ruoli limitati e dichiarati.
3. **Versionamento sperimentale.** Prompt, modelli, corpus, rubriche e casi devono essere tracciabili.
4. **Human-in-the-loop.** La validazione esperta non   opzionale quando l’output riguarda ragionamento clinico.

5. **Non-deployment clinico.** Il sistema è uno strumento di ricerca, formazione e valutazione, non un dispositivo medico.
6. **Riproducibilità locale.** Le componenti principali devono poter essere eseguite, ispezionate e sostituite in un ambiente controllato senza dipendere da servizi proprietari.




Figura 3: Architettura implementativa del prototipo locale. Il nucleo riproducibile è composto da frontend, API, database relazionale, datastore vettoriale, pipeline di estrazione, LLM locali e motore di benchmark. Le integrazioni GCP sono estensioni opzionali di deployment e non dipendenze del protocollo scientifico.




Figura 4: Architettura concettuale multi-agente. La decomposizione non rappresenta una moltiplicazione di chatbot, ma la separazione di responsabilità epistemiche: raccolta del caso, codifica nosologica, diagnosi differenziale, revisione benchmark, protocollo e sicurezza.

6.2 Agenti previsti

Agente	Funzione scientifica	Output ammesso
Clinical Intake Triage	Struttura la vignetta, identifica dati mancanti e decide il percorso successivo.	Sommario neutro, dati mancanti, rischio, handoff.

ICD-11 Coding Assistant	Recupera categorie ICD-11 candidate e requisiti diagnostici.	Candidati ICD-11, evidenze pro/contro, esclusioni, incertezza.
Differential Diagnosis Supervisor	Confronta ipotesi diagnostiche mantenendo separate evidenze e inferenze.	Tabella differenziale, condizioni da non perdere, domande successive.
Benchmark Case Reviewer	Verifica qualità dei casi DSM e rischio di leakage.	Readiness del caso, artefatti, contaminazioni, richieste di revisione umana.
Research Protocol Navigator	Aiuta a mantenere coerenza metodologica tra esperimenti.	Protocollo, metriche, rischi di validità, prossime azioni.
Safety and Scope Guardrail	Blocca uso clinico diretto, dati identificativi o rischio acuto.	Risposta sicura, escalation umana, delimitazione dello scope.

6.3 Condizioni sperimentali

Il paper propone di confrontare almeno cinque condizioni:

1. modello base senza retrieval;
2. modello con RAG non strutturato su ICD-11/CDDR;
3. modello con corpus statico locale e retrieval filtrato;
4. singolo agente generalista con accesso alle stesse fonti;
5. orchestrazione multi-agente con ruoli separati.

Queste condizioni permettono di isolare l'effetto del grounding, della strutturazione del corpus e della decomposizione agentica. La comparazione non deve essere ridotta alla sola accuracy diagnostica, perché un sistema più cauto ma meno assertivo può essere scientificamente preferibile a un sistema che indovina più spesso ma produce giustificazioni fragili. Un eventuale deployment su cloud o su piattaforme conversazionali gestite può essere riportato in appendice o come nota di trasferibilità tecnologica, ma non dovrebbe entrare nelle condizioni sperimentali principali.

7 Riproducibilità

La riproducibilità è un requisito centrale di LLMind2, non un attributo accessorio del software. Il primo lavoro LLMind aveva già posto attenzione alla descrizione della pipeline di costruzione del dataset, alla scelta del modello, alla configurazione RAG e alla valutazione su casi DSM-5-TR. La versione 2 estende tale impostazione rendendo espliciti tutti gli elementi che devono essere fissati prima dell'esperimento e conservati dopo l'esecuzione. L'obiettivo è consentire a un gruppo indipendente di ricostruire non soltanto l'applicazione, ma il disegno sperimentale: quali fonti sono state usate, come sono state trasformate, quali prompt sono stati inviati, quali modelli hanno risposto e come le risposte sono state valutate.

7.1 Riproducibilità dei dati

Le fonti devono essere descritte con versione, origine e procedura di estrazione. Per ICD-11, questo significa indicare endpoint o container API, data dell'estrazione, lingua, filtro sul Capitolo 6 e schema della tabella risultante. Per ICD-11-CDDR, occorre indicare edizione, formato sorgente, procedura di segmentazione e criterio di associazione tra testo descrittivo e categoria diagnostica. Per DSM-5-TR Clinical Cases, occorre documentare la procedura di separazione tra introduction, discussion e diagnosis, poiché questo passaggio determina il rischio di leakage e quindi la validità del benchmark.




Figura 5: Catena degli artefatti di riproducibilità. Ogni risultato sperimentale dovrebbe poter essere ricondotto a fonti, dataset, retrieval, prompt, modelli, parametri e procedure di valutazione.

Ogni record trasformato dovrebbe includere un identificatore stabile, un hash del contenuto sorgente o del chunk generato, il nome della pipeline di estrazione e la versione del codice usata. In questo modo, se una risposta del modello viene contestata, è possibile risalire al frammento recuperato e verificare se l'errore dipende dal modello, dal retrieval, dalla preparazione del dato o dal gold standard.

7.2 Riproducibilità del retrieval e dei prompt

Per ogni condizione sperimentale devono essere salvati prompt di sistema, prompt utente, template di retrieval, numero di documenti recuperati, soglie di similarità, strategia di chunking, modello di embedding e parametri di generazione. Nel caso multi-agente, deve essere registrato anche quale agente ha ricevuto il caso, quale handoff è stato attivato e quale contesto è stato passato all'agente successivo. Senza questa tracciabilità, due esecuzioni apparentemente identiche potrebbero differire in modo sostanziale.

La riproducibilità non richiede necessariamente determinismo perfetto, spesso impossibile con modelli generativi. Richiede però che le fonti di variabilità siano note e misurate. Per questa ragione, il protocollo dovrebbe fissare temperatura, top-p, seed quando disponibile, modello e versione del runtime. Quando il modello non consente pieno controllo del seed, il paper deve dichiararlo e prevedere esecuzioni ripetute o analisi di stabilità.

7.3 Riproducibilità dell'ambiente

L'ambiente minimo riproducibile dovrebbe essere locale e basato su strumenti ispezionabili: database relazionale per ICD-11 e casi, indice vettoriale locale, script di estrazione versionati, runtime LLM locale o modello open-weight eseguibile da terzi, e file di configurazione dichiarativi. L'uso di Docker o di ambienti equivalenti consente di fissare dipendenze, versioni e servizi necessari. Un deployment cloud può essere utile per scalare o mostrare una demo, ma non deve essere richiesto per riprodurre i risultati del paper.

7.4 Riproducibilità della valutazione

La valutazione deve essere ricostruibile come la pipeline tecnica. Devono essere archiviati l'elenco dei casi inclusi, i criteri di esclusione, le condizioni sperimentali, la rubrica esperta, le istruzioni ai valutatori, la forma delle risposte mostrate ai valutatori e l'eventuale randomizzazione. Le metriche automatiche devono essere calcolate da script versionati, mentre le valutazioni manuali devono conservare punteggio, valutatore, timestamp e note qualitative. Quando il materiale sorgente non può essere redistribuito per ragioni di copyright, il paper dovrebbe comunque descrivere procedure e schemi in modo sufficiente a permettere la replica da parte di chi possiede accesso legittimo alle stesse fonti.

Author action required. Preparare una tabella finale “Reproducibility artifacts” con: versione ICD-11, versione CDDR, numero di casi DSM, modelli, embedding, parametri generativi, schema dati, prompt template, rubrica, numero valutatori e commit/tag del codice.

8 Protocollo di valutazione

8.1 Task sperimentali

La valutazione dovrebbe includere task distinti:

- identificazione di diagnosi candidate da vignette DSM-5-TR;
- mapping tra diagnosi DSM e categorie ICD-11 candidate;
- generazione di diagnosi differenziale;
- rilevazione di dati mancanti;
- rilevazione di leakage nei casi;
- classificazione di richieste fuori perimetro o safety-sensitive.




Figura 6: Workflow di valutazione. Le metriche automatiche e la valutazione esperta sono mantenute separate e poi integrate nell’analisi degli errori, evitando di ridurre il reasoning diagnostico alla sola accuracy.

8.2 Metriche automatiche

Nel prototipo sono implementate metriche automatiche calcolate al termine di ogni run di benchmark e salvate insieme alla risposta del modello. La similarita semantica confronta embedding della risposta e della diagnosi gold standard. La label accuracy e un indicatore binario che verifica corrispondenza testuale o overlap lessicale sufficiente con la diagnosi attesa. Precision, recall e F1 sono calcolate su token normalizzati della risposta e del gold standard. Il flag “no diagnosis” identifica risposte vuote o astensive, distinguendo errore assertivo e mancata formulazione diagnostica. Latenza e valutazione umana sono conservate come dimensioni complementari.

8.3 Valutazione esperta

La valutazione esperta dovrebbe usare una rubrica a piu dimensioni:

- coerenza con il caso;
- appropriatezza nosologica;
- qualita della diagnosi differenziale;
- esplicitazione di esclusioni e dati mancanti;
- calibrazione dell’incertezza;
- assenza di overclaiming clinico;
- utilita per ricerca o formazione.

L’accordo tra valutatori puo essere stimato usando indici di concordanza, ad esempio concordance correlation coefficient quando appropriato [3]. La rubrica deve essere definita prima dell’esperimento, non adattata a posteriori.

Metrica	Definizione operativa	Implementata
Similarita semantica	Coseno tra embedding della risposta e embedding del gold standard.	Si
Label accuracy	Valore 1 se la diagnosi attesa appare nella risposta o se il richiamo lessicale supera la soglia; 0 altrimenti.	Si
Precision	Quota di token diagnostici della risposta presenti nel gold standard.	Si
Recall	Quota di token diagnostici del gold standard recuperati nella risposta.	Si
F1	Media armonica tra precision e recall.	Si
No diagnosis	Flag per risposte vuote, astensive o insufficienti.	Si
Top-k accuracy	Accuratezza su lista ordinata di candidati diagnostici. Richiede il salvataggio strutturato dei candidati.	Pianificata

Tabella 3: Metriche automatiche del benchmark. Le misure lessicali sono euristiche riproducibili e devono essere interpretate insieme alla valutazione esperta, non come prova di validita clinica.

Author action required. Servono almeno due valutatori esperti o, in alternativa, una giustificazione metodologica forte per una valutazione single-rater. Occorre decidere scala della rubrica: binaria, Likert 1–5, oppure punteggio continuo 0–1 come nel lavoro precedente.

8.4 Analisi degli errori

L’analisi degli errori deve distinguere categorie clinicamente e metodologicamente significative:

- diagnosi candidata assente;
- diagnosi corretta ma giustificazione errata;
- confusione DSM/ICD;
- esclusione mancante;
- dato mancante non rilevato;
- leakage dal prompt;
- allucinazione di codice o criterio;
- risposta troppo assertiva;
- risposta sicura ma poco utile.

Questa tassonomia permette di valutare se l’orchestrazione multi-agente riduce specifici errori anche quando non migliora immediatamente l’accuracy aggregata.

9 Ipotesi

Le ipotesi principali sono:

1. Il grounding su ICD-11/CDDR aumenta la qualita nosologica rispetto a prompt non ancorati.
2. Il retrieval filtrato su corpus statico riduce rumore e costo rispetto a retrieval documentale non strutturato.
3. La decomposizione multi-agente riduce overclaiming e leakage rispetto a un agente generalista.

4. La valutazione esperta mostrerà divergenze tra correttezza del label e qualità del reasoning, rendendo insufficiente la sola accuracy.

10 Considerazioni etiche e di governance

LLMind2 deve essere interpretato come piattaforma di ricerca. L'uso su pazienti reali, dati identificativi o situazioni di rischio richiede procedure esterne, approvazioni etiche e supervisione qualificata. Nel paper, il confine deve essere esplicito: il sistema supporta studio, benchmark e analisi metodologica; non produce diagnosi cliniche e non sostituisce valutazione professionale.

La governance dei dati è centrale. I casi DSM-5-TR sono materiale protetto da copyright e devono essere gestiti secondo licenza e finalità ammesse. Le fonti ICD-11 e CDDR devono essere citate correttamente. La configurazione raccomandata per gli esperimenti è locale o comunque controllata, in modo da minimizzare trasferimenti di dati verso servizi terzi. Eventuali interazioni con agenti cloud devono essere considerate extra-protocolliari, evitare dati personali e prevedere logging, minimizzazione e controllo degli accessi. Se in futuro saranno usati dati clinici reali, sarà necessario un protocollo etico dedicato, con de-identificazione, base giuridica, data protection impact assessment e revisione istituzionale.

Author action required. Indicare esplicitamente nel paper se la v2 usa solo casi pubblicati/sintetici o anche dati clinici reali. Se sono previsti dati reali, serve approvazione etica prima di qualunque esperimento.

11 Risultati attesi e piano di analisi

Questa bozza non riporta risultati empirici nuovi, perché la fase sperimentale della versione 2 deve ancora essere completata. Il paper è quindi strutturato come base per uno studio empirico: le sezioni di risultati dovranno essere popolate dopo l'esecuzione dei benchmark.

I risultati dovrebbero essere organizzati in quattro blocchi:

1. performance diagnostica e nosologica per condizione sperimentale;
2. valutazione esperta del reasoning;
3. analisi degli errori e dei failure modes;
4. latenza, costo computazionale locale e riproducibilità delle query agentiche.

Author action required. Dopo il primo run sperimentale, inserire: numero di casi, modelli testati, configurazione retrieval, versione corpus, numero valutatori, metriche aggregate, intervalli di confidenza se disponibili, e almeno 3 esempi qualitativi di successo/fallimento.

12 Minacce alla validità

12.1 Validità interna

La principale minaccia interna è il leakage. Se elementi della diagnosis o della discussion entrano nel prompt, la valutazione sovrastima la capacità del modello. Una seconda minaccia riguarda la variabilità del retrieval: versioni diverse del corpus o parametri diversi di chunking possono cambiare gli output. Una terza minaccia è la non-determinismo dei modelli generativi.

12.2 Validita esterna

I casi DSM-5-TR sono casi pubblicati e didattici. Non rappresentano necessariamente la distribuzione di complessita, incompletezza e ambiguita dei casi reali. Inoltre, risultati su vignette non implicano performance clinica in contesti operativi.

12.3 Validita di costruito

Accuracy diagnostica non misura pienamente la qualita del reasoning. Un output puo avere label corretta ma motivazione scorretta; oppure puo essere clinicamente prudente pur non producendo una label specifica. Per questo motivo, la valutazione deve includere dimensioni qualitative e safety-oriented.

12.4 Validita conclusiva

Campioni ridotti, numero limitato di valutatori e differenze tra DSM e ICD possono limitare la generalizzabilita. Le conclusioni dovranno essere formulate in termini di supporto sperimentale e non di efficacia clinica.

13 Contributi attesi

Il contributo scientifico della versione 2 puo essere riassunto in quattro punti:

1. un framework per studiare LLM ontology-grounded nel dominio della salute mentale;
2. un protocollo di benchmark che distingue label accuracy, reasoning quality e safety;
3. una proposta di orchestrazione multi-agente con ruoli epistemici separati;
4. una strategia di corpus statico e versionato, riproducibile localmente, per rendere retrieval e valutazione piu controllabili.

14 Conclusioni

LLMind2 estende il lavoro LLMind Chat trasformando un assistente RAG in una piattaforma di ricerca per il reasoning diagnostico assistito da LLM. Il punto centrale non e dimostrare che un modello possa sostituire un professionista, ma studiare in quali condizioni il grounding nosologico, la strutturazione del corpus, l'orchestrazione agentica e la valutazione human-in-the-loop possano rendere l'uso dei LLM piu trasparente, controllabile e scientificamente valutabile.

La versione 2 propone un passaggio concettuale rilevante: dal chatbot come interfaccia al sistema come laboratorio. In un dominio ad alto rischio epistemico come la salute mentale, tale passaggio e essenziale. Solo separando fonti, compiti, vincoli e metriche e possibile capire se i LLM contribuiscano realmente alla qualita del ragionamento o se producano soltanto spiegazioni linguisticamente plausibili. Il lavoro futuro consistera nell'eseguire il protocollo, completare la validazione esperta, pubblicare risultati riproducibili e valutare l'impatto della decomposizione multi-agente sui failure modes piu critici.

Checklist rapida per completare il paper

1. Confermare titolo, autori, affiliazioni e venue target.
2. Decidere quali modelli confrontare nella v2.
3. Eseguire benchmark su casi DSM-5-TR con condizioni sperimentali definite.
4. Coinvolgere valutatori esperti e congelare la rubrica prima della valutazione.
5. Inserire risultati quantitativi, esempi qualitativi e analisi degli errori.
6. Verificare licenze e permessi per citare o descrivere casi DSM-5-TR.

7. Decidere se includere figure: architettura concettuale, flusso agentico, protocollo di valutazione.

Riferimenti bibliografici

- [1] American Psychiatric Association. *Diagnostic and Statistical Manual of Mental Disorders, Fifth Edition, Text Revision (DSM-5-TR)*. American Psychiatric Association Publishing, Washington, DC, 2022. doi: 10.1176/appi.books.9780890425787.
- [2] American Psychiatric Association. *DSM-5-TR Clinical Cases*. American Psychiatric Association Publishing, Washington, DC, 2023.
- [3] Huiman X. Barnhart, Michael Haber, and Jincheng Song. Overall concordance correlation coefficient for evaluating agreement among multiple observers. *Biometrics*, 58(4):1020–1027, 2002. doi: 10.1111/j.0006-341X.2002.01020.x.
- [4] Marco Cremaschi, Davide Ditolve, Cesare Curcio, Anna Panzeri, Andrea Spoto, and Andrea Maurino. Decoding the mind: A rag-llm on icd-11 for decision support in psychology. *Expert Systems with Applications*, 279:127191, 2025. doi: 10.1016/j.eswa.2025.127191.
- [5] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Kuttler, Mike Lewis, Wen-tau Yih, Tim Rocktaschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive nlp tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474, 2020.
- [6] Huayang Li, Yixuan Su, Deng Cai, Yan Wang, and Lemao Liu. A survey on retrieval-augmented text generation. *arXiv preprint arXiv:2202.01110*, 2022. URL <https://arxiv.org/abs/2202.01110>.
- [7] Cheng Peng, Xi Yang, Aokun Chen, Kaleb E. Smith, Nima PourNejatian, Anthony B. Costa, Cheryl Martin, Mona G. Flores, Ying Zhang, Tanja Magoc, Gloria Lipori, Duane A. Mitchell, Natalia S. Ospina, Mustafa M. Ahmed, William R. Hogan, Elizabeth A. Shenkman, and Jiang Bian. A study of generative large language model for medical research and healthcare. *NPJ Digital Medicine*, 6(1):210, 2023. doi: 10.1038/s41746-023-00958-w.
- [8] Karan Singhal, Shekoofeh Azizi, Tao Tu, S. Sara Mahdavi, Jason Wei, Hyung Won Chung, Nathan Scales, Ajay Tanwani, Heather Cole-Lewis, Stephen Pfohl, Perry Payne, Manish Seneviratne, Paul Gamble, Chris Kelly, Nathanael Scharli, Aakanksha Chowdhery, Philip Mansfield, Dina Demner-Fushman, Cecilia Aguerrebere, Dale Webster, Greg S. Corrado, Yossi Matias, Katherine Chou, Juraj Gottweis, Nenad Tomasev, Yun Liu, Alvin Rajkomar, Joelle Barral, Christopher Semturs, Alan Karthikesalingam, and Vivek Natarajan. Large language models encode clinical knowledge. *Nature*, 620(7972):172–180, 2023. doi: 10.1038/s41586-023-06291-2.
- [9] World Health Organization. International classification of diseases, eleventh revision (icd-11), 2022. URL <https://icd.who.int/>. Accessed 2026-06-21.
- [10] World Health Organization. *Clinical descriptions and diagnostic requirements for ICD-11 mental, behavioural and neurodevelopmental disorders*. World Health Organization, Geneva, 2024. URL <https://www.who.int/publications/i/item/9789240077263>.